



2022-2 통계수문학

MIDTERM PROJECT REPORT

2020-10420 박준명

1. 매개변수 추정법

매개변수 추정이란 내가 갖고 있는 표본이 어떤 확률밀도함수 $f(x|\theta)$ 를 따른다고 가정할 때, 이 표본으로 확률밀도 함수의 parameter인 θ 를 추정하는 것을 말한다. 매개 변수는 뒤에서 다루게 될 MLE, MoM, L-moment, Bayesian inference이외에도 다양한 방법을 통해 추정할 수 있다.

(1) Maximum Likelihood Estimation (MLE)

MLE는 우도(Likelihood)라는 개념의 도입을 통해 우도가 최대가 되도록 하는 parameter θ 를 추정하는 방법이다. 여기서 우도란 내가 갖고 있는 표본이 어떤 분포로부터 나왔을 가능성 즉 확률으로, 각 표본이 가정한 분포에서 등장하는 확률을 모두 곱한 것을 말하고 이를 likelihood function이라 한다. likelihood function을 수학적으로 서술하면 아래와 같다.

$$L(x|\theta) = \prod_{i=1}^n f(x_i|\theta)$$

이 likelihood function을 가장 크게 하는 parameter θ 를 구하여 그 값을 추정 매개변수 $\hat{\theta}_{MLE}$ 로 한다. 보통 미분을 통해 $\hat{\theta}_{MLE}$ 를 구하는데, 확률의 곱의 형태이기에 미분이 어려워 likelihood function에 log를 취한 log-likelihood function을 미분하여 아래와 같이 $\hat{\theta}_{MLE}$ 를 구한다.

$$\frac{\partial}{\partial \theta} \log L(x|\theta) = \frac{\partial}{\partial \theta} \sum_{i=1}^n \log f(x_i|\theta) = 0$$

(2) Method of Moments (MoM)

MoM은 표본자료의 표본 모멘트가 확률분포의 이론적인 모멘트와 같다고 가정하여 parameter를 구하는 방법이다. 이때 이론적인 모멘트는 아래와 같다.

$$1차\ moment\ (mean): E[X] = \bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$2차\ moment\ (variance): E[(X - \mu)^2] = S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$3차\ moment\ (skewness): E[(X - \mu)^3] = g_x$$

$$= \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \frac{(x_i - \bar{x})^3}{S_x^3}$$

⋮

$$n차\ moment : E[(X - \mu)^n]$$

위의 식에 따라 n개의 parameter에 대해 n개의 방정식을 얻게 되고, 이를 연립방정식으로 풀어 $f(x|\theta)$ 의 parameter $\hat{\theta}_{MoM}$ 을 추정할 수 있다.

(3) Method of L-moments

Method of L-moments는 위에서 소개한 Method of Moments를 보완하기 위해 제안된 방법으로 확률가중모멘트(PWM)의 선형조합으로 parameter를 표현한다. 여기서 PMW란 위에서 사용한 확률 모멘트를 해당 분포로 가중한 것으로, $PMW(\beta_r)$ 은 아래와 같이 정의한다.

$$\beta_r = E\{X[F(X)]^r\}$$

이렇게 정의한 PMW를 바탕으로 아래와 같이 L-moment($\lambda_1, \lambda_2, \lambda_3, \lambda_4$)를 정의할 수 있다.

$$\lambda_1 = \beta_0$$

$$\lambda_2 = 2\beta_1 - \beta_0$$

$$\lambda_3 = 6\beta_2 - 6\beta_1 + \beta_0$$

$$\lambda_4 = 20\beta_3 - 30\beta_2 + 12\beta_1 - \beta_0$$


이렇게 구한 L-moment의 비로 아래와 같이 L-variation, L-skewness, L-kurtosis를 정의할 수 있고, 이를 MoM의 variation, skewness, kurtosis와 같이 사용할 수 있다.

$$\tau_2 = \frac{\lambda_2}{\lambda_1} \text{ (coefficient of } L\text{-variation)}$$

$$\tau_3 = \frac{\lambda_3}{\lambda_2} \text{ (} L\text{-skewness)}$$

$$\tau_4 = \frac{\lambda_4}{\lambda_2} \text{ (} L\text{-kurtosis)}$$

이렇게 구한 L-skewness와 L-kurtosis를 바탕으로 L-moment ratio Diagram을 그릴 수 있고, 이 diagram에 도시한 자료가 분포에 얼마나 적합한지 확인할 수 있다.(Fig-1)



〈Figure - 1〉 L-moment Diagram

(4) Bayesian inference

Bayesian inference란 사전확률과 우도를 바탕으로 사후확률을 업데이트하는 베이즈 이론을 바탕으로 한 parameter 추정방법으로, 사전확률 $p(\theta)$ 와 이 parameter에 대응하는 $p(X|\theta)$ 가 주어졌을 때 베이즈 정리를 이용하여 데이터가 주어졌을 때 parameter를 추정할 수 있고 그 과정은 아래와 같다.

$$P(\theta|X) = \frac{P(\theta)P(X|\theta)}{\sum P(\theta)P(X|\theta)} \text{ (discrete)}$$

$$= \frac{f(\theta)f(X|\theta)}{\int f(\theta)f(X|\theta)d\theta} \text{ (continuous)}$$

이 사후분포를 계산하기 위해서 parameter를 3가지 방법으로 추정할 수 있다. 아래의 수식들은 parameter를 추정하는 방법으로 순서대로 각각 베이즈 추정량, 사후 메디안 추정량, MAP 추정량(Maximum a posterior)이다. 베이즈 추정량은 사후분포의 MSE(Mean Squared Error)를 최소화하는 방법이고, 사후 메디안 추정량은 사후분포의 MAE(Mean Absolute Error)를 최소화하는 방법이다. 마지막으로 MAP 추정량은 maximum likelihood를 갖는 θ 를 찾는 방법이다.

$$\hat{\theta}(x) = \underset{\theta}{\operatorname{argmin}} \int_{\theta} |t - \theta|^2 f(\theta|x) d\theta$$

$$\hat{\theta}(x) = \underset{\theta}{\operatorname{argmin}} \int_{-\infty}^{\infty} |t - \theta| f(\theta|x) d\theta$$

$$\hat{\theta}(x) = \underset{\theta}{\operatorname{argmax}} \frac{f(\theta)f(X|\theta)}{\int f(\theta)f(X|\theta)d\theta}$$


보통 Bayesian Inference를 진행함에 MAP 추정량 방법을 많이 사용하고, 이렇게 구한 사후분포를 사전확률로 업데이트 하여 iteration을 진행함에 따라 보다 정확한 모수 추정을 진행할 수 있다.

2. 실제 데이터 사용 매개변수 추정 법 비교

(1) 데이터 소개


대상 유역과 자료는 전라북도 진안군에 위치한 용담댐의 2001년부터 2021년 까지의 일 유입량 자료를 선택하였다.

용담댐의 경우 금강에 최상류에 존재하는 댐이고, 저수량이 국내 5위에 해당하는 큰 댐이기에 유입량에 인공적인 요인 즉 상류댐의 영향이 적고, 2001년부터 준공되어 약 20여년 운영되어 분석에 필요한 충분한 데이터를 확보할 수 있다.



〈Figure - 2〉 Yongdam Dam Inflow

위에서 볼 수 있듯 용담댐의 일 유입량은 주로 6월~9월의 홍수기에 집중된 것을 확인할 수 있다.(Fig-2) 따라서 전체 유입량, 홍수기(6월~9월) 유입량, 비홍수기 유입량, 극치 유입량 총 4개의 자료를 구성하고 4개의 데이터에 알맞은 분포 및 모수를 추정하였다.




〈Figure - 3〉 Mean Residual Life Plot (Inflow)

극치 유입량의 경우 연별 최대 강우량을 뽑게 된다면 데이터의 수가 적어 분석이 어려울 것으로 판단하여, POT 방법을 사용하여 200cms를 넘는 유입량을 극치 유입량 자료로 선정하여 분석을 진행하였다. (Fig-3)

(2) 방법 별 적용 및 비교

우선 전체 데이터에 대해 log를 씌우고 히스토그램을 그려본 결과 아래와 같이 정규분포 모형을 보이는 것을 확인하였다.(Fig-4) 따라서 유입량 분포가 lognormal 분포를 따를 것이라 추정하였고, lognormal과 유사한 gamma분포, Weibull 분포에 대해 AIC 값을 비교하여 확률분포를 추정하였다.




〈Figure - 4〉 Histogram (log 10 Inflow)


그 결과 전체, 홍수기, 비홍수기 자료모두 Table 1에 따르면, lognormal 분포에서의 AIC 값이 가장 작게 나와 lognormal 분포를 따를 확률이 큰 것을 확인하였다. 추가적으로 세 자료 모두 P-P plot을 통해 lognormal 분포가 적절한 분포라는 사실을 확인하였다. (Fig -5,6,7) 또, 홍수기 자료에서는 AIC값이 23133.74, 비홍수기 자료에서는 32996.4로 전체 자료의 AIC값인 57293.03보다 훨씬 작은 값을 얻을 수 있었다. 따라서 유입량 자료는 홍수기와 비 홍수기 총 두가지 분포로 나누어서 분석하는 것이 적절하다는 것을 확인하였다.

〈Table - 1〉 AIC comparison


AIC	lognorm	Gamma	Weibull
Whole	57293.03	60936.76	59400.39
Flood season	23133.74	24186.08	23751.35
nonFlood season	32996.4	33497.83	33397.82



〈Figure - 5〉 P-P Plot (Inflow_Whole)




〈Figure-6〉 P-P Plot (Inflow_Flood season)



〈Figure-7〉 P-P Plot (Inflow_nonFlood season)

극치 자료의 경우 POT 방법을 사용하였으므로, GPD분포를 따른다고 가정하고, P-P plot을 그려본 결과 거의 직선인 모습을 보여 GPD 분포로 가정한 것이 타당하다는 것을 확인하였다.



〈Figure - 8〉 P-P Plot (Inflow_extreme)


이렇게 구한 분포에 적합한 모수추정을 위해 MLE 기법, MoM기법 2가지 방법에 대해 모수 추정을 진행하였다.

전체, 홍수기, 비홍수기 자료 모두 lognormal 분포를 따르는 것을 확인하였으므로, 모수 추정법 비교의 경우 중복된 분포는 제외하고, AIC값이 가장 낮았던 홍수기 자료만 이용하여 모수 추정법간 비교를 진행하였다. 이때, 모수 추정의 정확도는 Chi-square test의 p-value 비교를 통해 진행하였다. 그 결과 MLE방법으로 추정하

분포에서는 p-value가 0.003, MoM방법으로 추정한 분포에서는 p-value는 0.00000128로 얻을 수 있었다.(Table - 2)

〈Table - 2〉 Parameters for lognormal distribution

method	meanlog	sdlog	p-value
MLE	2.757	1.458	0.003448
MoM	2.93	1.41	0.00000128




〈Figure - 9〉 Histogram & Distribution (Inflow_Flood season, log10 scale)

같은 방법으로 GPD 분포에 대해서도 MLE방법과 MoM 방법간 모수 추정 비교를 진행하였다. 여기서 모멘트법은 eva 패키지에서 제공하는 PWM(확률가중 모멘트법)을 이용하여 비교하였다. 그 결과 MLE법에서는 p-value가 0.06732, PMW에서는 p-value가 0.06657을 얻을 수 있었다.

〈Table - 3〉 Parameters for GPD

method	xi	beta	p-value
MLE	0.1669	213.3869	0.06732
PWM	0.1740	211.2558	0.06657



〈Figure - 10〉 Histogram & Distribution (Inflow_extreme)

(3) 결과 분석

위의 결과에 따르면 MoM 방법이 MLE방법에 비해 p-value가 대체적으로 낮게 나오는 결과를 얻을 수 있었다. 카이제곱검정에서 p-value는 분포와 자료의 일치도가 높을수록 낮은 값을 보여 귀무가설을 기각하지 못하므로 MoM 방법이 MLE방법에 비해 정확하게 모수를 추정하는 것을 확인하였다.

이는 일반적으로 MLE가 수학적 방법을 통한 계산이라는 점에서 더 높은 정확도를 보일 것이라는 예상에서 벗어난 결과인데, 이는 자료의 자체의 편향 혹은 outlier를 처리하는 과정에서 편이가 발생하였기 때문으로 추정되고, MLE방법이 정확도가 매우 높은 방법은 아님을 확인하였다.

GPD 방법을 이용한 극치 추정의 경우 p-value가 0.05보다 높은 값을 나타냈는데, 이는 극치 데이터의 경우 chi-square 검정법에 따라 유의수준 95%에서 가설을 기각할 수 있음을 의미한다. 따라서 더 정확한 분포추정을 위해 자료가 더 많은 데이터를 사용하거나, 다른 극치분포와의 비교가 필요할 것으로 보인다.

위에서 비교한 두가지 방법 이외에도 위에서 소개한 L-moment 법은 일반적인 모멘트 법에서 샘플의 개수가 작은 경우 추정 모수가 biased 될 수 있는데, L-moment 법에서는 선형조합으로 연결하기에 이런 문제를 해결할 수 있고, L-moment Daigram을 통해 다양한 자료의 특성을 도시적으로 비교할 수 있다는 장점이 있다.

Bayesian Inference는 반복된 Iteration을 통해 보다 정확한 모수를 추정할 수 있고, 내가 가정한 분포가 조금 다르더라도, 자료에 알맞은 적절한 분포를 반복 시행에 따라 찾아간다는 장점이 존재하지만, 처음 우도 함수를 잘못 설정한다면 이 과정이 오래 걸린다는 단점도 존재한다.

3. 미국, 우리나라의 홍수 빈도 분석 비교

(1) 한국의 홍수 빈도분석

한국의 홍수 빈도분석 및 홍수량 산정은 2019년 환경부에서 발간한 홍수량 산정 표준지침에 따라 분석이 이루어진다. 홍수량 빈도 해석을 위해서는 확률강우량을 산정해야 하는데, 확률강우량 산정은 지역빈도해석을 권장하고, 최적 확률분포는 GEV 분포형으로 한다. 지역빈도해석의 수행 및 적용이 용이하지 않은 경우, 지점빈도해석을 통해 확률강우량을 산정하고 이때 확률분포형은 Gumbel 분포형으로 한다.

확률분포의 매개변수 추정방법으로는 확률가중모멘트법(PWM)을 원칙으로 하고, 재현기간이 커지며 지나치게 크게 산정되는 경우, 모멘트법과 최우도법(MLE)을 통해 추가적인 검토를 진행한다.



〈Figure - 11〉 지점빈도해석 절차

이렇게 구한 확률 강우량의 경우 면적 확률 강우량과 지점확률 강우량으로 구분되고, 유역면적이 25.9 km² 이상인 경우 면적 확률 강우량을 적용한다. 홍수량 계산을 위해서는 확률 강우량뿐 아니라, 지속시간도 중요한데 강우의 시간분포를 구하는 방법은 집중호우 기준으로 작성된 수정 Huff방법을 적용한다.

위에서 구한 면적 확률 강우량과 강우의 시간분포에 유역특성인자, 유효유량에 따른 유출곡선지수 등을 강우 유출모형에 대입하여 최종적으로 홍수량을 산정하여 특정 홍수량의 홍수 빈도를 확인할 수 있다. 이때 강우-유출 모형은 Clark 단위도법을 사용한다.

우리나라의 경우 홍수량 자료가 절대적으로 부족하고, 기존 수위-유량관계곡선 간의 정확도가 낮아 홍수량 자

료 계열 자체의 신뢰도가 낮은 문제점이 존재하기에 더 많은 연구와 보완을 필요로 한다.

(2) 미국의 홍수 빈도분석

미국은 USGS(US Geological Survey)에서 발간한 Bulletin 17B/17C를 기반으로 홍수빈도 분석 및 홍수량 산정을 수행한다. 미국의 경우 한국과 거의 유사하나, 최적 확률분포를 GEV분포가 아닌, log-Pearson 3 distribution을 사용한다.

매개변수 추정의 경우 간단한 경우, 모멘트 법으로 추정하고, 보다 정확한 추정이 필요한 경우 가중 모멘트법 혹은 EMA(Expected Moments Algorithm)를 사용한다. 또한 보다 정확한 추정을 위해 지역적인 skewness를 반영하거나, 비슷한 유역간의 비교 등을 진행하기도 한다. 이렇게 추정한 Frequency를 바탕으로 extrapolation을 통해 홍수 빈도분석을 진행한다.

미국의 경우에도 토지이용 변화 및 도시화로 인한 홍수 빈도의 변동반영, 미개척 유역에 대한 자료부족, 수문학적 혹은 수문 기상학적으로 혼합된 분포의 처리 등에서 아직 미흡한 모습을 보이고 있고 이를 보완할 점으로 지적하고 있다.

4. Reference

- 홍수량 산정 표준지침. 2019. 환경부
- Guidelines for Determining Flow Flow Frequency Bulletin 17C.2019. US Geological Survey
- 이동진. 허준행. L-모멘트법을 이용한 한강유역 일강우량자료의 지역빈도해석. 2001. 한국수자원학회
- 용담댐 유역 비점오염 저감시설 설치 및 관리방안 연구. 2019. 한국수자원공사
- Enrico Fabrizi, Carlo Trivisano. Bayesian Estimation of Log-Normal Means with Finite Quadratic Expected Loss. 2012. Bayesian Analysis